Held-out MCC-S across all datasets

Gemma-2-2B

Dataset	SSAE L1	SSAE Step-L0	SSAE sigmoid-L0	SSAE ReLU	SSAE JumpReLU	SSAE TopK	SAE ReLU	SAE JumpReLU	SAE TopK
ENG→FR	0.362 ± 0.297	0.864 ± 0.000	0.864 ± 0.000	0.319 ± 0.070	0.864 ± 0.000	0.828 ± 0.027	0.048 ± 0.044	0.819 ± 0.032	0.780 ± 0.073
ENG→DE	0.421 ± 0.207	0.864 ± 0.000	0.859 ± 0.007	0.129 ± 0.091	0.864 ± 0.000	0.864 ± 0.000	0.334 ± 0.163	0.854 ± 0.007	0.806 ± 0.072
GENDER	0.866 ± 0.000	0.866 ± 0.000	0.866 ± 0.000	0.254 ± 0.187	0.866 ± 0.000	0.789 ± 0.093	0.364 ± 0.203	0.852 ± 0.009	0.865 ± 0.002
BINARY	0.804 ± 0.029	0.740 ± 0.019	0.826 ± 0.016	0.134 ± 0.008	0.752 ± 0.027	0.649 ± 0.109	0.100 ± 0.084	0.727 ± 0.008	0.680 ± 0.071
CORR	0.765 ± 0.157	0.288 ± 0.188	0.862 ± 0.015	0.108 ± 0.032	0.847 ± 0.013	0.851 ± 0.011	0.199 ± 0.035	0.811 ± 0.027	0.746 ± 0.047
TruthfulQA	0.332 ± 0.108	0.646 ± 0.028	0.613 ± 0.039	0.126 ± 0.022	0.370 ± 0.091	0.419 ± 0.044	0.182 ± 0.027	0.484 ± 0.054	0.469 ± 0.061
Sycophancy	0.353 ± 0.138	0.054 ± 0.039	0.671 ± 0.049	0.135 ± 0.100	0.177 ± 0.074	0.213 ± 0.140	0.187 ± 0.068	0.173 ± 0.122	0.154 ± 0.071
Refusal	0.586 ± 0.341	0.513 ± 0.310	0.792 ± 0.040	0.113 ± 0.136	0.685 ± 0.158	0.384 ± 0.076	0.620 ± 0.055	0.558 ± 0.099	0.381 ± 0.269
Bias-in-Bios	0.224 ± 0.003	0.194 ± 0.000	0.205 ± 0.001	0.343 ± 0.003	0.147 ± 0.005	0.437 ± 0.005	0.419 ± 0.005	0.216 ± 0.002	0.393 ± 0.008

Pythia-70M

Dataset	SSAE L1	SSAE Step-L0	SSAE sigmoid-L0	SSAE ReLU	SSAE JumpReLU	SSAE TopK	SAE ReLU	SAE JumpReLU	SAE TopK
ENG→FR	0.105 ± 0.036	0.850 ± 0.010	0.767 ± 0.076	0.424 ± 0.116	0.840 ± 0.018	0.497 ± 0.183	0.184 ± 0.049	0.506 ± 0.075	0.757 ± 0.033
ENG→DE	0.189 ± 0.127	0.786 ± 0.029	0.789 ± 0.096	0.143 ± 0.159	0.822 ± 0.016	0.473 ± 0.132	0.156 ± 0.047	0.729 ± 0.027	0.712 ± 0.084
GENDER	0.104 ± 0.058	0.757 ± 0.071	0.788 ± 0.065	0.086 ± 0.053	0.744 ± 0.048	0.327 ± 0.151	0.358 ± 0.110	0.588 ± 0.192	0.379 ± 0.092
BINARY	0.379 ± 0.071	0.577 ± 0.033	0.612 ± 0.074	0.154 ± 0.037	0.573 ± 0.006	0.158 ± 0.103	0.105 ± 0.023	0.436 ± 0.059	0.271 ± 0.019
CORR	0.530 ± 0.091	0.491 ± 0.047	0.682 ± 0.038	0.160 ± 0.076	0.626 ± 0.024	0.327 ± 0.035	0.222 ± 0.080	0.538 ± 0.025	0.431 ± 0.066
TruthfulQA	0.214 ± 0.121	0.213 ± 0.023	0.532 ± 0.040	0.119 ± 0.065	0.408 ± 0.056	0.135 ± 0.074	0.247 ± 0.046	0.394 ± 0.016	0.372 ± 0.030
Sycophancy	0.385 ± 0.086	0.737 ± 0.008	0.677 ± 0.086	0.387 ± 0.003	0.508 ± 0.098	0.452 ± 0.048	0.391 ± 0.007	0.754 ± 0.003	0.298 ± 0.113
Refusal	0.274 ± 0.124	0.217 ± 0.098	0.517 ± 0.050	0.123 ± 0.057	0.536 ± 0.135	0.312 ± 0.110	0.115 ± 0.088	0.191 ± 0.030	0.212 ± 0.098
Bias-in-Bios	0.141 ± 0.000	0.121 ± 0.002	0.168 ± 0.001	0.154 ± 0.005	0.138 ± 0.003	0.180 ± 0.003	0.193 ± 0.003	0.137 ± 0.002	0.210 ± 0.002