Held-out R^2 across all datasets

Gemma-2-2B

Dataset	SSAE L1	SSAE Step-L0	SSAE sigmoid-L0	SSAE ReLU	SSAE JumpReLU	SSAE TopK	SAE ReLU	SAE JumpReLU	SAE TopK
ENG→FR	0.757 ± 0.038	0.939 ± 0.001	0.947 ± 0.001	0.717 ± 0.035	0.855 ± 0.007	0.850 ± 0.012	0.618 ± 0.055	0.885 ± 0.009	0.864 ± 0.021
ENG→DE	0.611 ± 0.052	0.937 ± 0.005	0.947 ± 0.000	0.633 ± 0.030	0.849 ± 0.006	0.857 ± 0.017	0.785 ± 0.023	0.853 ± 0.010	0.887 ± 0.001
GENDER	0.939 ± 0.010	0.953 ± 0.003	0.987 ± 0.002	0.524 ± 0.039	0.896 ± 0.008	0.899 ± 0.025	0.168 ± 0.237	0.853 ± 0.021	0.830 ± 0.049
BINARY	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.537 ± 0.038	0.436 ± 0.062	0.113 ± 0.160	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000
CORR	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000
TruthfulQA	0.527 ± 0.030	0.537 ± 0.017	0.150 ± 0.114	0.433 ± 0.018	0.274 ± 0.105	0.603 ± 0.007	0.000 ± 0.000	0.377 ± 0.037	0.588 ± 0.052
Sycophancy	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000
Refusal	0.747 ± 0.004	0.724 ± 0.003	0.656 ± 0.027	0.470 ± 0.041	0.650 ± 0.049	0.668 ± 0.013	0.496 ± 0.352	0.632 ± 0.022	0.774 ± 0.010
Bias-in-Bios	0.285 ± 0.000	0.277 ± 0.000	0.263 ± 0.000	0.319 ± 0.001	0.274 ± 0.001	0.341 ± 0.003	0.280 ± 0.112	0.311 ± 0.002	0.373 ± 0.006

Pythia-70M

Dataset	SSAE L1	SSAE Step-L0	SSAE sigmoid-L0	SSAE ReLU	SSAE JumpReLU	SSAE TopK	SAE ReLU	SAE JumpReLU	SAE TopK
ENG→FR	0.685 ± 0.025	0.741 ± 0.048	0.848 ± 0.009	0.628 ± 0.045	0.700 ± 0.018	0.337 ± 0.064	0.550 ± 0.011	0.715 ± 0.018	0.565 ± 0.018
ENG→DE	0.634 ± 0.074	0.709 ± 0.050	0.859 ± 0.013	0.561 ± 0.012	0.705 ± 0.006	0.411 ± 0.036	0.533 ± 0.025	0.703 ± 0.004	0.550 ± 0.049
GENDER	0.446 ± 0.317	0.728 ± 0.026	0.730 ± 0.023	0.736 ± 0.026	0.755 ± 0.011	0.556 ± 0.021	0.411 ± 0.006	0.755 ± 0.029	0.658 ± 0.081
BINARY	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.370 ± 0.263	0.000 ± 0.000	0.043 ± 0.061	0.183 ± 0.114	0.000 ± 0.000	0.000 ± 0.000
CORR	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.084 ± 0.119	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000
TruthfulQA	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.185 ± 0.024
Sycophancy	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000
Refusal	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.210 ± 0.032	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.000 ± 0.000	0.050 ± 0.036
Bias-in-Bios	0.138 ± 0.000	0.119 ± 0.000	0.156 ± 0.000	0.164 ± 0.001	0.161 ± 0.000	0.135 ± 0.002	0.183 ± 0.000	0.162 ± 0.000	0.164 ± 0.001